

Szakedolgozat bírálólat

Czotter Benedek

szigorló mérnökinformatikus hallgató részére

Klaszterezési technikák alkalmazása az embedding-alapú visszakeresés hatékonyságának növelésére RAG környezetben

című dolgozatához

A szakdolgozat a Retrieval-Augmented Generation (RAG) rendszerek visszakereső moduljának hatékonyságnövelésével foglalkozik, különös tekintettel a klaszterezési technikák alkalmazására. A témaválasztás rendkívül időszerű és releváns, hiszen a nagyméretű nyelvi modellek (LLM-ek) egyre szélesebb körű elterjedésével a RAG-rendszerek kulcsszerepet kaptak a tudásalapú mesterséges intelligencia területén. A téma aktualitását igazolja, hogy a jelenlegi ipari gyakorlatban a RAG-rendszerek egyik legnagyobb kihívása a skálázhatóság és a valós idejű működés biztosítása nagy mennyiségű dokumentum esetén. A jelölt által vizsgált probléma – a keresési idő csökkentése a pontosság minimális romlása mellett – gyakorlati jelentőséggel bír mind a tudományos kutatásban, mind az ipari alkalmazásokban.

A szerző bemutatta a RAG-architektúra elméleti hátterét, majd kifejlesztett egy saját Online KMeans algoritmust, amely valós időben integrálja az új dokumentumokat a klaszterstruktúrába újraklaszterezés nélkül, támogatva a dinamikus klaszter-létrehozást és összevonást. A kétlépcsős retrieval-módszer először centroid-szinten, majd a legjobb klasztereken belül keres. A kísérleteket SQuAD adathalmazon végezte, brute force és FAISS HNSW összehasonlítással.

A jelölt a kitűzött feladatot teljes mértékben megoldotta. A dolgozat a feladatkiírásnak megfelelően tartalmazza a klaszterezési algoritmusok összehasonlító elemzését, egy online klaszterezési módszer implementációját, valamint a retrieval-folyamat hatékonyságának részletes kiértékelését. Az elméleti háttér kellő mélységben kerül bemutatásra, az implementációs részletek világosak. A kiértékelés átfogó, kiterjed mind a minőségi (pontosság, recall), mind a hatékonysági (futásidő, frissítési idő) szempontokra. Kiemelendő, hogy a jelölt egy innovatív Online KMeans algoritmust is kifejlesztett, amely valós idejű adatfolyamok kezelésére alkalmas.

A dolgozat logikus felépítésű, a gondolatmenet világos és követhető. A RAG-rendszerek ismertetése után a szerző fokozatosan vezeti be az olvasót a klaszterezési technikák alkalmazásába. A problémafelvetés és a megoldási javaslat kapcsolata jól kidolgozott.

Az alkalmazott módszerek helyesen vannak megválasztva: a koszinusz hasonlóság és L2-normalizálás indokolt a magas dimenziós embedding térben. Az Online KMeans matematikai megfogalmazása precíz, a kiértékelési metrikák (accuracy, recall, ARI, NMI) megfelelőek, az idő- és memória komplexitás elemzése alapos.

Az eredmények értékesek: a kidolgozott Online KMeans hasonló ARI/NMI értékeket ért el, mint a klasszikus KMeans, de gyorsabb frissítéssel. A MiniBatchKMeans-hez képest hasonló teljesítményt nyújt, miközben kevésbé érzékeny a kezdeti adathalmaz méretére. A kétlépcsős retrieval mindössze 1-2% pontosságvesztéssel járt a brute force-hoz képest, jelentős idő- és számítási megtakarítás mellett.

Összefoglalva, a jelölt kiváló mérnöki képességekről tett tanúbizonyságot. A dolgozat átfogó képet nyújt a vizsgált területről, fokozatosan szűkítve a fókuszot a RAG-rendszerek visszakereső moduljára. Az Online KMeans algoritmus önálló és innovatív fejlesztés a dinamikus klaszterezés területén. A kísérleti kiértékelés részletes, a különböző módszerek összehasonlítása több metrika mentén történt. A dolgozat szerkezete logikus, a bemutatás világos, az ábrák és táblázatok informatívak.

A dolgozattal kapcsolatban a következő kérdéseket tenném fel:

1. A dolgozatban a retrieval során alkalmazott 0,6-os hasonlósági küszöbérték a chunkolási eljárásból származik. Milyen hatással lenne a rendszer teljesítményére ennek a paraméternek a változtatása?
2. Milyen területeken jelenthet előnyt a kidolgozott Online KMeans algoritmus, illetve alkalmazás során milyen limitációkat érdemes szem előtt tartani?

Összességében a szakdolgozat elfogadását javaslom.



Szántó Tamás
Senior Software Engineer
Hearsay, a Yext company

Budapest, 2025. december 29.